

PyClef: Reconhecimento Óptico de Partituras com MIRP

Vinícius Fernandes Silvestre, Samir Angelo Milani Martins *

* GCoM - Grupo de Controle e Modelagem, Departamento de Engenharia Elétrica, Universidade Federal de São João del Rei, MG
E-mails: vitinhovinius8@gmail.com, martins@ufsj.edu.br

Abstract: This work presents PyClef, a system for Optical Music Recognition (OMR) that integrates deep learning-based object detection and structured musical inference. The detection stage employs the YOLOv11S architecture to identify 208 classes of musical symbols in the DeepScoresV2 (Dense) dataset, achieving $mAP@[0.5 : 0.95] = 0.4126$. However, geometric detection metrics are not sufficient to correctly reconstruct the musical score. To overcome this limitation, the Staff-Referenced Musical Inference Method (MIRP) was proposed, in which the detected clef and the staff structure are used to define a reference note, allowing the pitch of the remaining notes to be inferred from their relative vertical displacement. Experimentally, the Pitch Reconstruction Rate increased from approximately 4% to 97.5% using the YOLOv11S model. The results demonstrate that the explicit incorporation of structural knowledge of musical notation constitutes a superior alternative to the isolated use of deep learning-based detectors in OMR tasks.

Resumo: Este trabalho apresenta o PyClef, um sistema para Reconhecimento Óptico de Partituras Musicais (*Optical Music Recognition* – OMR) que integra detecção de objetos baseada em aprendizado profundo e inferência musical estruturada. A etapa de detecção utiliza a arquitetura YOLOv11S para identificar 208 classes de símbolos musicais no conjunto DeepScoresV2 (Dense), obtendo $mAP@[0,5 : 0,95] = 0,4126$. Entretanto, métricas geométricas de detecção não são suficientes para reconstruir corretamente a partitura. Para superar essa limitação, foi proposto o Método de Inferência Musical por Referência de Pauta (MIRP), no qual a clave detectada e a estrutura da pauta são utilizadas para definir uma nota de referência, permitindo inferir a altura das demais notas a partir de seu deslocamento vertical relativo. Experimentalmente, a Taxa de Reconstrução de Altura evoluiu de aproximadamente 4% para 97,5% utilizando o modelo YOLOv11S. Os resultados demonstram que a incorporação explícita de conhecimento estrutural da notação musical constitui uma alternativa superior ao uso isolado de detectores baseados em aprendizado profundo em tarefas de OMR.

Keywords: Optical Music Recognition; Deep Learning; Object Detection; Structural Modeling; PyClef.

Palavras-chaves: Reconhecimento Óptico de Partituras Musicais; Aprendizado Profundo; Detecção de Objetos; Modelagem Estrutural; PyClef.

1. INTRODUÇÃO

O Reconhecimento Óptico de Partituras Musicais (*Optical Music Recognition* – OMR) tem como objetivo converter partituras musicais em representações digitais estruturadas (Balke et al., 2015; Woo, 2024). Essa tarefa é relevante para a preservação de acervos musicais históricos, indexação de documentos musicais e integração com ferramentas de edição, síntese sonora e ensino de música. Apesar dos avanços recentes em visão computacional e aprendizado profundo, o reconhecimento automático de partituras ainda apresenta desafios significativos, especialmente em cenários caracterizados por alta densidade simbólica e grande diversidade de elementos gráficos.

Em partituras complexas, múltiplos símbolos musicais podem ocorrer em regiões muito próximas, frequentemente com sobreposição visual e forte desbalanceamento entre classes. Nessas condições, pequenos erros de localização ou classificação podem comprometer a interpretação correta da estrutura musical. Esse problema torna-se ainda mais evidente em bases de dados como o DeepScoresV2 (Dense) (Tuggenier et al., 2021), que reúne centenas de classes de símbolos musicais distribuídos em imagens com elevada densidade gráfica.

Nos últimos anos, abordagens baseadas em detecção de objetos utilizando redes neurais convolucionais têm apresentado resultados promissores para OMR. Arquiteturas da família YOLO (Balakrishnan et al., 2022), por exemplo, permitem identificar símbolos musicais diretamente em imagens de partituras com elevada eficiência computacional. Entretanto, tais abordagens frequentemente tratam

* Este trabalho foi financiado por FAPEMIG, CAPES, CNPq e UFSJ.

o problema como uma tarefa predominantemente visual, focando na detecção geométrica dos símbolos e desconsiderando relações estruturais próprias da notação musical. Como consequência, detecções visualmente corretas nem sempre resultam em reconstruções musicais semanticamente consistentes, especialmente na determinação da altura das notas.

Neste contexto, este trabalho apresenta o PyClef, um sistema para OMR que integra detecção de objetos baseada em aprendizado profundo e inferência musical estruturada. A etapa de detecção emprega a arquitetura YOLOv11S para identificar 208 classes de símbolos musicais no conjunto DeepScoresV2 (Dense), sendo também realizada uma comparação com a variante YOLOv11L em termos de desempenho e custo computacional. Como principal contribuição, propõe-se o Método de Inferência Musical por Referência de Pauta (MIRP), no qual a clave detectada e a estrutura da pauta são utilizadas para definir uma nota de referência, permitindo inferir a altura das demais notas a partir de seu deslocamento vertical relativo.

Os resultados experimentais demonstram que as detecções produzidas diretamente pelo modelo YOLO não são suficientes para reconstruir corretamente as notas da partitura, resultando em Taxa de Reconstrução de Altura próxima de 4%. Após a incorporação do MIRP à saída do detector, esse valor aumentou para aproximadamente 97,5%, evidenciando a importância do método proposto na reconstrução musical da partitura.

2. CONCEITOS PRELIMINARES

Esta seção apresenta os principais conceitos teóricos necessários para compreender o funcionamento do sistema proposto. São abordados fundamentos de representação de imagens digitais, detecção de objetos em visão computacional e métricas utilizadas na avaliação de modelos de detecção.

2.1 Representação de Imagens Digitais

Uma imagem digital pode ser representada como uma função discreta bidimensional que associa a cada posição espacial um valor de intensidade ou cor. Formalmente, uma imagem pode ser descrita como

$$I(x, y) \quad (1)$$

em que (x, y) representam as coordenadas espaciais de um pixel na imagem e $I(x, y)$ corresponde ao valor de intensidade ou cor associado a esse pixel.

Em aplicações de visão computacional, imagens digitais são frequentemente representadas como matrizes discretas (Silva et al., 2010). Dessa forma, uma imagem pode ser descrita como

$$I \in R^{H \times W \times C} \quad (2)$$

em que:

- H representa a altura da imagem em pixels;
- W representa a largura da imagem em pixels;
- C corresponde ao número de canais de cor da imagem.

Por exemplo, em imagens RGB, $C = 3$, correspondendo aos canais vermelho, verde e azul.

2.2 Detecção de Objetos

A detecção de objetos consiste na tarefa de localizar e classificar instâncias de objetos presentes em uma imagem. Em modelos modernos de detecção, cada objeto identificado é representado por uma caixa delimitadora (*bounding box*), definida como

$$b = (x, y, w, h, c) \quad (3)$$

em que:

- (x, y) representam as coordenadas do centro da caixa delimitadora;
- w corresponde à largura da caixa;
- h corresponde à altura da caixa;
- c representa a classe do objeto detectado.

No contexto de reconhecimento óptico de partituras musicais (*Optical Music Recognition – OMR*), essas caixas delimitadoras são utilizadas para localizar símbolos musicais como notas, pausas, claves e outros elementos presentes na partitura.

2.3 Intersection over Union

Para avaliar a qualidade da localização das caixas delimitadoras previstas por um modelo, utiliza-se frequentemente a métrica *Intersection over Union* (IoU), definida como

$$IoU = \frac{|B_p \cap B_{gt}|}{|B_p \cup B_{gt}|} \quad (4)$$

em que:

- B_p representa a caixa delimitadora prevista pelo modelo;
- B_{gt} corresponde à caixa anotada no conjunto de dados de referência (*ground truth*);
- $\cap$ representa a operação de interseção entre as caixas;
- $\cup$ representa a operação de união entre as caixas.

Valores de *IoU* próximos de 1 indicam maior sobreposição entre as caixas comparadas (Sun et al., 2024), refletindo maior precisão na localização do objeto.

2.4 Métricas de Avaliação

A avaliação de modelos de detecção de objetos é frequentemente realizada por meio das métricas *Precision* e *Recall*, (Wei et al., 2018) e (Oksuz et al., 2022), definidas respectivamente como

$$Precision = \frac{TP}{TP + FP} \quad (5)$$

$$Recall = \frac{TP}{TP + FN} \quad (6)$$

em que:

- TP (*True Positives*) representa o número de detecções corretas;

- *FP* (*False Positives*) corresponde ao número de detecções incorretas;
- *FN* (*False Negatives*) indica o número de objetos presentes na imagem que não foram detectados pelo modelo.

Com base nessas métricas, calcula-se a *Average Precision* (AP), que corresponde à área sob a curva *Precision-Recall* para uma determinada classe.

2.5 Mean Average Precision

Em problemas com múltiplas classes, a métrica mais utilizada para avaliar modelos de detecção de objetos é o *Mean Average Precision* (mAP) (Yang et al., 2011), definido como

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (7)$$

em que:

- N corresponde ao número total de classes consideradas no problema;
- AP_i representa a *Average Precision* associada à classe i .

Em avaliações modernas de detecção de objetos, como no protocolo do benchmark COCO (Puri, 2019), a métrica mAP é frequentemente calculada considerando diferentes limiares de *Intersection over Union* (IoU). Nesse caso, utiliza-se a notação $mAP@[0.5 : 0.95]$, em que esse intervalo não representa possíveis valores resultantes da métrica, mas sim os limiares de IoU utilizados em seu cálculo.

Assim, o AP é calculado para múltiplos valores de IoU variando de 0.5 a 0.95, com incrementos de 0.05, e o resultado final corresponde à média obtida entre esses limiares.

Formalmente, essa métrica pode ser expressa como

$$mAP@[0.5 : 0.95] = \frac{1}{T} \sum_{t=1}^T AP_{IoU_t} \quad (8)$$

em que:

- IoU_t representa um dos limiares de IoU considerados no intervalo de 0.5 a 0.95;
- AP_{IoU_t} corresponde ao valor de *Average Precision* calculado para o limiar IoU_t ;
- T indica o número total de limiares utilizados.

Essa métrica fornece uma avaliação mais rigorosa do desempenho do modelo, pois considera simultaneamente diferentes níveis de precisão na localização dos objetos detectados.

3. METODOLOGIA

Esta seção descreve a metodologia empregada no desenvolvimento da biblioteca PyClef para reconhecimento óptico de partituras musicais. Inicialmente, apresenta-se o pipeline geral do sistema. Em seguida, são detalhadas a etapa

de detecção de símbolos musicais e o Método de Inferência Musical por Referência de Pauta (MIRP), principal contribuição deste trabalho.

3.1 Pipeline do Sistema

O funcionamento geral do sistema proposto é ilustrado na Figura 1. O PyClef recebe como entrada uma imagem contendo uma partitura musical e executa uma sequência de etapas para identificar símbolos musicais e reconstruir a informação musical correspondente.

Inicialmente, a imagem é processada por um modelo de detecção de objetos, responsável por localizar símbolos musicais e classificá-los. Como saída, obtém-se um conjunto de detecções contendo classes e respectivas *bounding boxes*.

Em seguida, as detecções são submetidas ao MIRP, responsável por utilizar a clave detectada e a geometria da pauta musical para inferir a altura das notas identificadas.

Por fim, o sistema gera uma representação estruturada da partitura com base nas informações extraídas nas etapas anteriores.




Figura 1. Pipeline do sistema PyClef, composto pelas etapas de detecção de símbolos musicais e inferência musical via MIRP.

3.2 Detecção de Símbolos Musicais

A etapa de detecção foi implementada utilizando modelos da família YOLO (*You Only Look Once*) (Bokash et al., 2025), amplamente empregados em tarefas de detecção de objetos por realizarem localização e classificação em uma única passagem pela rede neural.

A família YOLO disponibiliza diferentes variantes de escala, frequentemente identificadas pelas letras *n* (*nano*), *s* (*small*), *m* (*medium*) e *l* (*large*), que representam modelos com diferentes capacidades representacionais e custos computacionais (Wang et al., 2025). Em geral, variantes maiores possuem maior número de parâmetros e maior custo de processamento, podendo apresentar melhor desempenho em tarefas mais complexas.

Neste trabalho, a variante YOLOv11S foi adotada como arquitetura principal devido ao seu equilíbrio entre desempenho e custo computacional. O modelo foi treinado para identificar 208 classes de símbolos musicais presentes no dataset DeepScoresV2 (Dense) (Tuggener et al., 2021).

Durante o processo de inferência, a rede recebe como entrada uma imagem de partitura e retorna um conjunto de detecções contendo as classes identificadas e suas respectivas *bounding boxes*.

Adicionalmente, realizou-se uma comparação experimental com a variante YOLOv11L, correspondente à versão *large* da arquitetura, com o objetivo de analisar o impacto do aumento da capacidade representacional no desempenho final do sistema.

3.3 Método de Inferência Musical por Referência de Pauta (MIRP)

Embora detectores de objetos sejam capazes de localizar símbolos musicais, a identificação correta da altura das notas depende da interpretação de relações estruturais entre clave, pauta e posição vertical dos símbolos.

Para lidar com essa limitação, propõe-se o Método de Inferência Musical por Referência de Pauta (MIRP). Inicialmente, a clave detectada e a primeira linha inferior da pauta são utilizadas para definir uma nota de referência musical. A partir dessa referência, a altura das demais notas é inferida por meio de seu deslocamento vertical relativo na pauta.

O espaçamento médio entre posições adjacentes da pauta é estimado por

$$d_{staff} = \frac{y_b - y_t}{8} \quad (9)$$

em que:

- y_t representa a coordenada vertical superior da pauta detectada;
- y_b representa a coordenada vertical inferior da pauta detectada;
- d_{staff} corresponde ao passo vertical entre posições consecutivas.

Em seguida, calcula-se a posição relativa da nota detectada:

$$\Delta p = \frac{y_{ref} - y_{note}}{d_{staff}} \quad (10)$$

em que:

- y_{note} representa a coordenada vertical do centro da nota detectada;
- y_{ref} corresponde à posição vertical da nota de referência;
- Δp indica o deslocamento relativo da nota na pauta.

Por fim, a nota musical resultante é obtida por

$$n = n_{ref} + \Delta p \quad (11)$$

em que:

- n_{ref} representa a nota de referência definida pela clave;
- Δp corresponde ao deslocamento relativo calculado;
- n indica a nota musical inferida.

Esse procedimento permite transformar informações geométricas extraídas da imagem em representação musical simbólica, incorporando explicitamente conhecimento estrutural da notação musical ao sistema proposto.

4. RESULTADOS

4.1 Desempenho Quantitativo

A etapa de detecção de símbolos musicais foi implementada utilizando a variante YOLOv11S, selecionada como núcleo do sistema PyClef em função de seu menor custo computacional e desempenho competitivo quando associada ao método proposto. No conjunto de validação do DeepScoresV2 (Dense), composto por 208 classes, o modelo alcançou $mAP@[0,5 : 0,95] = 0,4126$, sendo $[0,5 : 0,95]$ o intervalo de limiares de IoU empregados no cálculo da métrica.

A métrica $mAP@[0,5 : 0,95]$ foi calculada conforme o protocolo COCO, isto é, pela média do *Average Precision* (AP) em múltiplos limiares de *Intersection over Union* (IoU) no intervalo $[0,5, 0,95]$, com incremento de 0,05.

Para fins de análise comparativa, também foi treinada a variante YOLOv11L, caracterizada por maior profundidade e número de parâmetros. Ambos os modelos foram treinados sob condições experimentais idênticas, utilizando o mesmo particionamento do conjunto de dados, estratégia de otimização e ambiente computacional.

Os experimentos foram conduzidos em um notebook equipado com GPU NVIDIA GTX 1650 Ti (4 GB de VRAM) e 16 GB de memória RAM. O treinamento foi realizado com 100 épocas, (*batch size*) igual a 2, *patience* de 20 épocas, quatro *workers*, peso da perda de localização (*box*) igual a 7.5, peso da perda de classificação (*cls*) igual a 1.5 e resolução de entrada (*imgsz*) de 1024 pixels.

O valor máximo de $mAP@[0,5 : 0,95]$ obtido durante o treinamento foi utilizado como critério de comparação entre as arquiteturas. Os resultados são apresentados na Tabela 1.

Tabela 1. Comparação entre as variantes YOLOv11 avaliadas.

Modelo	$mAP@[0,5 : 0,95]$
YOLOv11S	0.4126
YOLOv11L	0.51379

Observa-se que a arquitetura YOLOv11L apresentou maior desempenho na métrica $mAP@[0,5 : 0,95]$, com ganho relativo aproximado de 24,5% em relação à variante YOLOv11S. Esse resultado era esperado devido à maior capacidade representacional do modelo. Entretanto, tal ganho foi acompanhado por maior custo computacional e maior tempo de treinamento, evidenciando o compromisso entre desempenho geométrico e eficiência computacional.

4.2 Impacto do MIRP

Embora a métrica $mAP@[0,5 : 0,95]$ avalie rigorosamente a qualidade geométrica das detecções, ela não garante a reconstrução musical semanticamente correta da partitura. Em particular, a determinação da altura, *pitch*, das notas




Figura 2. Comparação da Taxa de Reconstrução de Altura (TRA) com e sem a aplicação do MIRP para as variantes YOLOv11S e YOLOv11L.

depende da relação espacial entre a nota detectada, a clave e a estrutura da pauta musical.

Para avaliar esse aspecto funcional, definiu-se a Taxa de Reconstrução de Altura (TRA):

$$TRA = \frac{N_{corretas}}{N_{total}}, \quad (12)$$

em que:

- $N_{corretas}$ corresponde ao número de notas cuja altura foi corretamente inferida;
- N_{total} representa o número total de notas avaliadas.

A Tabela 2 e a Figura 2 apresentam os resultados obtidos antes e após a aplicação do Método de Inferência Musical por Referência de Pauta (MIRP).

Tabela 2. Impacto do MIRP na reconstrução musical.

Modelo	TRA sem MIRP	TRA com MIRP
YOLOv11S (PyClef)	0.04	0.975
YOLOv11L	0.08	0.971

Os resultados demonstram que as saídas produzidas diretamente pelo modelo YOLO não são suficientes para reconstruir corretamente as notas da partitura. Após a incorporação do MIRP, ambas as arquiteturas passaram a apresentar desempenho superior a 97% na reconstrução de altura.

Observa-se ainda que, após a aplicação do método proposto, a diferença de desempenho entre YOLOv11S e YOLOv11L torna-se desprezível. Esse comportamento indica que a principal contribuição para o desempenho final do sistema está associada ao MIRP, permitindo o uso de modelos mais leves sem perda significativa de desempenho funcional.

4.3 Interface Gráfica e Validação Funcional

Com o objetivo de consolidar o pipeline proposto em uma ferramenta operacional, foi desenvolvida uma interface gráfica utilizando PySide6 (Figura 3), permitindo a execução integrada das etapas de detecção, inferência musical e exportação de resultados.

Figura 3. Interface gráfica do sistema PyClef. Em visualizadores compatíveis, a figura pode ser exibida de forma animada.

A interface possibilita o carregamento de imagens ou arquivos PDF de partituras, aplicação automática do modelo treinado e geração das partituras reconstruídas com as notas identificadas, validando a execução completa do pipeline proposto.

4.4 Avaliação Qualitativa

Além da análise quantitativa, realizou-se avaliação qualitativa das detecções e da reconstrução simbólica gerada pelo sistema. As Figuras 4 e 5 apresentam exemplos da saída intermediária do detector e do resultado final após a aplicação do pipeline completo do PyClef.




Figura 4. Partitura após a identificação dos símbolos musicais.

As figuras evidenciam que a etapa de detecção fornece a base geométrica necessária para a atuação do MIRP, o qual utiliza a clave de referência e a geometria da pauta musical para identificar corretamente cada nota e viabilizar a reconstrução final da partitura.

5. CONCLUSÃO

Este trabalho propôs o Método de Inferência Musical por Referência de Pauta (MIRP), uma abordagem voltada à reconstrução musical de partituras a partir das detecções geométricas produzidas por modelos de visão computacional. O método utiliza a clave identificada e a estrutura da pauta musical para definir uma nota de referência e, a partir dela, inferir corretamente a altura das demais notas por meio de sua posição vertical relativa.




Figura 5. Partitura reconstruída após a aplicação do MIRP.

Os resultados experimentais demonstraram que métricas tradicionais de detecção, como o $mAP@[0, 5 : 0, 95]$, não são suficientes para representar o desempenho funcional de sistemas de OMR. Utilizando apenas a saída do detector, a Taxa de Reconstrução de Altura (TRA) permaneceu inferior a 10%. Após a aplicação do MIRP, esse valor atingiu aproximadamente 97%, evidenciando que a principal contribuição para o reconhecimento correto da partitura está associada ao método proposto.

Observou-se ainda que, após a incorporação do MIRP, a diferença prática entre modelos de maior e menor complexidade tornou-se reduzida, permitindo a utilização de arquiteturas mais leves sem perda significativa de desempenho final.

Como consequência da técnica desenvolvida, foi implementado o sistema PyClef, que consolida o pipeline completo em uma ferramenta funcional para processamento automático de partituras musicais. Atualmente, o software encontra-se disponível para uso público, instalação via PyPI e acesso à documentação oficial em: <https://viniciusfs14.github.io/PyClef/>.

Como trabalhos futuros, pretende-se expandir o MIRP para lidar com partituras musicais mais complexas, como acordes, múltiplas vozes, além de fazer sua integração com a base de dados com mais classes do DeepScore.

AGRADECIMENTOS

Os autores agradecem à FAPEMIG, CAPES, UFSJ e CNPq.

REFERÊNCIAS

- Balakrishnan, B., Chelliah, R., Venkatesan, M., and Sah, C. (2022). Comparative study on various architectures of yolo models used in object recognition. In *2022 International Conference on Computing, Communication, and Intelligent Systems (ICCCIS)*, 685–690. doi:10.1109/ICCCIS56430.2022.10037635.
- Balke, S., Achankunju, S.P., and Müller, M. (2015). Matching musical themes based on noisy ocr and omr input. In *2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 703–707. doi:10.1109/ICASSP.2015.7178060.

- Bokash, M., Almaktari, A., and Humbe, V.T. (2025). Pushing the limits of real-time face detection: A comparative analysis of yolov11 models. In *2025 5th International Conference on Emerging Smart Technologies and Applications (eSmarTA)*, 1–6. doi:10.1109/eSmarTA66764.2025.11132186.
- Oksuz, K., Cam, B.C., Kalkan, S., and Akbas, E. (2022). One metric to measure them all: Localisation recall precision (lrp) for evaluating visual detection tasks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(12), 9446–9463. doi:10.1109/TPAMI.2021.3130188.
- Puri, D. (2019). Coco dataset stuff segmentation challenge. In *2019 5th International Conference On Computing, Communication, Control And Automation (ICCUBEA)*, 1–5. doi:10.1109/ICCUBEA47591.2019.9129255.
- Silva, I.N.d., Spatti, D.H., and Flauzino, R.A. (2010). *Redes neurais artificiais para engenharia e ciências aplicadas*. Artliber Editora.
- Sun, Y., Wang, J., Wang, H., Zhang, S., You, Y., Yu, Z., and Peng, Y. (2024). Fused-iou loss: Efficient learning for accurate bounding box regression. *IEEE Access*, 12, 37363–37377. doi:10.1109/ACCESS.2024.3359433.
- Tugener, L., Satyawan, Y.P., Pacha, A., Schmidhuber, J., and Stadelmann, T. (2021). The deepscoresv2 dataset and benchmark for music object detection. In *2020 25th International Conference on Pattern Recognition (ICPR)*, 9188–9195. doi:10.1109/ICPR48806.2021.9412290.
- Wang, C.H., Yen, J.J., and Chen, W.R. (2025). Comparative analysis of palmprint detection using different yolo models. In *2025 1st International Conference on Consumer Technology (ICCT-Pacific)*, 1–4. doi:10.1109/ICCT-Pacific63901.2025.11012861.
- Wei, Z., Cui, Y., Zhou, X., Yang, W., Li, Y., Yi, X., and Dai, H. (2018). A research on metric learning in computer vision and pattern recognition. In *2018 Tenth International Conference on Advanced Computational Intelligence (ICACI)*, 254–259. doi:10.1109/ICACI.2018.8377616.
- Woo, N.H. (2024). Absolute pitch: Automatic sheet music navigation based on real-time music recognition. In *2024 International Conference on Artificial Intelligence, Big Data, Computing and Data Communication Systems (icABCD)*, 1–7. doi:10.1109/icABCD62167.2024.10645276.
- Yang, W., Feng, Q., Lu, Z., and Chen, W. (2011). Metric learning for maximizing map and its application to content-based medical image retrieval. In *2011 IEEE International Symposium on Biomedical Imaging: From Nano to Macro, 1901–1904*. doi:10.1109/ISBI.2011.5872780.